

BÁO CÁO ĐÁNH GIÁ ĐỘ TIN CẬY CỦA CÁC NGUỒN TÀI LIỆU

Chủ đề: Đánh giá Thiên kiến, Đạo đức và Tính công bằng trong các Mô hình Ngôn ngữ Lớn

Phạm vi tìm kiếm: Phân tích nguồn gốc, cách đo lường và các biện pháp giảm thiểu thiên kiến trong AI, từ cấp độ dữ liệu, mô hình đến các đánh giá mang tính xã hội học. Đây là một chủ đề có tính thách thức rất cao do sự phát triển công nghệ diễn ra với tốc độ chóng mặt, đòi hỏi tài liệu phải có tính cập nhật liên tục và độ xác thực khoa học sâu sắc,.

1. TIÊU CHÍ ĐÁNH GIÁ ĐỘ TIN CẬY

Mỗi tài liệu được đánh giá một cách có hệ thống dựa trên 5 tiêu chí cốt lõi:

- Tác giả:** Chuyên môn, uy tín học thuật và sự liên kết với các viện nghiên cứu, trường đại học hàng đầu.
- Cơ quan xuất bản:** Uy tín của tạp chí, kỷ yếu hội nghị hoặc tổ chức phát hành.
- Phương pháp nghiên cứu:** Tính chặt chẽ, hệ thống dữ liệu, độ minh bạch và khả năng tái lập của thực nghiệm.
- Trích dẫn:** Số lượng trích dẫn và chất lượng của danh mục tài liệu tham khảo.
- Tính cập nhật:** Thời gian xuất bản so với tiến trình phát triển của các công nghệ AI hiện đại nhất.

2. ĐÁNH GIÁ CHI TIẾT ƯU VÀ NHƯỢC ĐIỂM CỦA TỪNG LOẠI NGUỒN

Chủ đề này đã thu thập được 13 tài liệu đa dạng, bao gồm 6 loại nguồn khác nhau (Tạp chí khoa học, Kỷ yếu hội nghị, Tiền ấn bản, Báo cáo tổ chức, Sách học thuật, và Blog/Website). Trong đó, có 7 bài báo khoa học chất lượng cao đã qua bình duyệt.

2.1. Các bài báo khoa học chất lượng cao

Đây là nguồn thông tin có độ tin cậy cao nhất, định hình các phương pháp luận cốt lõi trong ngành.

- Bài báo trên Tạp chí khoa học:**
 - Bai et al. (2025) - PNAS:** Được xuất bản bởi Viện Hàn lâm Khoa học Quốc gia Hoa Kỳ, nghiên cứu này có độ tin cậy xuất sắc. *Ưu điểm:* Phương pháp nghiên cứu đột phá khi áp dụng các bài kiểm tra tâm lý học (LLM Word Association Test) để đo lường thiên kiến ngầm mà các LLM đang cố che giấu. *Nhược điểm:* Quá tập trung vào thiên kiến ngầm mà ít đề cập đến giải pháp kỹ thuật triệt để.

- **Peters & Chin-Yee (2025) - Royal Society Open Science:** *Ưu điểm:* Tính minh bạch rất cao thông qua quy trình bình duyệt mở (open peer-review). Dữ liệu lớn với 10 mô hình LLM được thử nghiệm để tìm ra "thiên kiến khái quát hóa" trong tóm tắt nghiên cứu khoa học.
- **Liu et al. (2025) - INFORMS Journal on Computing:** *Ưu điểm:* Cung cấp một khuôn khổ toán học chặt chẽ và phương pháp học tăng cường (reinforcement learning) nhằm giảm thiểu thiên kiến về tuổi tác (Age-Related Bias) mà không cần thay đổi thông số gốc của mô hình,.
- **Chand et al. (2026) - AI (MDPI):** Bài báo cực kỳ cập nhật (phát hành đầu năm 2026). *Ưu điểm:* Đánh giá thực nghiệm toàn diện trên 10 mô hình, chỉ ra rủi ro khi việc giảm thiểu thiên kiến ở một khía cạnh có thể làm trầm trọng thêm thiên kiến ở khía cạnh khác (spillover effects). *Nhược điểm:* Tạp chí thuộc hệ thống MDPI đôi khi có quy trình xuất bản nhanh, đòi hỏi người đọc phải tự kiểm chứng mã nguồn (code).
- **Kỷ yếu Hội nghị hàng đầu:**
 - **Bender et al. (2021) - FAccT:** *Ưu điểm:* Dù xuất bản năm 2021, đây là bài báo nền tảng nổi tiếng về khái niệm "Stochastic Parrots", cảnh báo rủi ro về quy mô dữ liệu và sự mã hóa thiên kiến xã hội, . Lượng trích dẫn khổng lồ chứng minh uy tín tuyệt đối.
 - **Dai et al. (2025) - EMNLP:** *Ưu điểm:* Xuất bản tại hội nghị hàng đầu về xử lý ngôn ngữ tự nhiên. Phương pháp rất hệ thống khi xây dựng bộ dữ liệu *AllSides-2024* độc lập để đo lường thiên kiến chính trị trong các trích dẫn do LLM tạo ra,.
 - **Donkor (2025) - AAI:** *Ưu điểm:* Hội nghị AI danh giá nhất. Thiết kế prompt chặt chẽ để khám phá cách các bối cảnh mập mờ kích hoạt thiên kiến trong lĩnh vực y tế và tuyển dụng,.

2.2. Tài liệu Tiền ấn bản:

- **Guo et al. (2024) & Lee, M.H.J. & Lai, C.K. (2025):**
 - *Ưu điểm:* Cung cấp thông tin tổng quan mới nhất (Survey), và những phát hiện tức thời về thiên kiến ngầm trong các "Mô hình suy luận" (Reasoning Models),.
 - *Nhược điểm:* Chưa trải qua quy trình bình duyệt (peer-review) chính thức nên độ tin cậy học thuật ở mức Khá, cần đối chiếu với các nguồn đã xuất bản.

2.3. Báo cáo Tổ chức & Sách học thuật

- Stanford HAI - The 2025 AI Index Report:** *Ưu điểm:* Được biên soạn bởi Viện Stanford HAI uy tín, báo cáo này mang đến cái nhìn vĩ mô, tổng hợp dữ liệu khách quan từ nhiều nguồn toàn cầu về cả kỹ thuật, rủi ro, và chính sách đạo đức AI,.. Độ tin cậy Rất Cao.
- Sách học thuật (Cambridge Univ. Press - 2024):** *Ưu điểm:* Cung cấp góc nhìn triết học và nền tảng pháp lý về AI,. *Nhược điểm:* Thiếu các đánh giá thực nghiệm bằng mã nguồn máy tính.

2.4. Các nguồn khác:

- Holm, E.M. (ZMO Blog):** *Ưu điểm:* Mang lại lăng kính độc đáo về cách AI xử lý Luật Hồi giáo (Islamic Law). *Nhược điểm:* Là bài blog do thực tập sinh viết, thiếu hệ thống tham khảo hàn lâm và bình duyệt khoa học. Độ tin cậy Thấp - Trung bình.
- ACL Ethics Committee (The Whole List):** Cơ sở dữ liệu thư mục chuyên ngành. *Ưu điểm:* Cấu trúc rõ ràng, hỗ trợ tìm kiếm tài liệu.

3. BẢNG TỔNG HỢP VÀ XẾP HẠNG ĐỘ TIN CẬY

STT	Tác giả (Năm)	Nguồn / Cơ quan xuất bản	Loại tài liệu	Xếp hạng Độ tin cậy	Nhận xét trọng tâm
1	Bai et al. (2025)	PNAS	Bài báo Tạp chí	Rất Cao	Khám phá thiên kiến ngầm bằng tâm lý học; dữ liệu cực tốt.
2	Bender et al. (2021)	FAccT (ACM)	Kỷ yếu Hội nghị	Rất Cao	Bài báo nền tảng, có tầm ảnh hưởng lịch sử lớn về đạo đức AI.
3	Stanford HAI (2025)	Stanford University	Báo cáo Tổ chức	Rất Cao	Nguồn dữ liệu vĩ mô toàn diện, khách quan nhất thế giới.
4	Dai et al. (2025)	EMNLP	Kỷ yếu Hội nghị	Cao	Đánh giá xuất sắc về thiên kiến chính trị qua bộ dataset mới.

5	Liu et al. (2025)	INFORMS Journal	Bài báo Tạp chí	Cao	Khung toán học vững chắc, bình duyệt nghiêm ngặt.
6	Peters & Chin-Yee (2025)	Royal Society Open Science	Bài báo Tạp chí	Cao	Phân tích thiên kiến tóm tắt khoa học với open peer-review.
7	Donkor (2025)	AAAI	Kỷ yếu Hội nghị	Cao	Đóng góp giá trị trong phân tích bối cảnh prompt.
8	Chand et al. (2026)	MDPI AI	Bài báo Tạp chí	Khá - Cao	Tính cập nhật rất cao, tuy nhiên thuộc NXB Open Access MDPI.
9	Cambridge U. Press	Cambridge Univ. Press	Sách học thuật	Khá - Cao	Nền tảng triết học tốt nhưng thiếu thực nghiệm tính toán.
10	Lee & Lai (2025)	arXiv (Preprint)	Tiền ấn bản	Khá	Tính cập nhật mạnh mẽ về "Reasoning models" nhưng chưa bình duyệt.
11	Guo et al. (2024)	arXiv (Preprint)	Tiền ấn bản (Survey)	Khá	Tổng hợp tài liệu phong phú, hữu ích cho tra cứu tổng quan.
12	ACL Ethics (2025)	Assoc. for Comp. Linguistics	Website / Thư mục	Trung bình	Nguồn tra cứu thư mục tham khảo thứ cấp, do cộng đồng đóng góp.
13	Holm, E.M. (2024)	ZMO Blog	Blog / Bài viết web	Thấp	Quan điểm thú vị nhưng thiếu chuẩn mực nghiên cứu khoa học.

4. KẾT LUẬN

Báo cáo đã khai thác thành công 13 tài liệu trải dài qua 6 loại nguồn, bao gồm 7 bài báo khoa học chất lượng cao từ các NXB và hội nghị top-tier (PNAS, AAAI, EMNLP, Royal Society). Nhìn chung, đối với chủ đề kỹ thuật - xã hội như "Đạo đức AI", các hội nghị khoa học (như EMNLP, AAAI, FAccT) và tạp chí mở như PNAS cung cấp độ tin cậy thực nghiệm

cao nhất. Ngược lại, các tiền ấn bản và blog dù mang lại góc nhìn rất hiện đại nhưng cần được đối chiếu chéo để đảm bảo tính xác thực.

5. DANH MỤC TÀI LIỆU THAM KHẢO:

ACL Ethics Committee, 2025. *The Whole List - ACL Ethics*. Association for Computational Linguistics.

Bai, X., Wang, A., Sucholutsky, I. and Griffiths, T.L., 2025. Explicitly unbiased large language models still form biased associations. *Proceedings of the National Academy of Sciences*, 122(8), p.e2416228122.

Bender, E.M., Gebru, T., McMillan-Major, A. and Shmitchell, S., 2021. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜 . In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency* (pp. 610-623).

Buckner, C.J. et al., 2024. *AI, Ethics and Philosophy (Part I) - The Cambridge Handbook of the Law, Ethics and Policy of Artificial Intelligence*. Cambridge: Cambridge University Press.

Chand, S., Baca, F. and Ferrara, E., 2026. No Free Lunch in Language Model Bias Mitigation? Targeted Bias Reduction Can Exacerbate Unmitigated LLM Biases. *AI*, 7(1), p.24.

Dai, S., Cao, Z., Wang, W., Pang, L., Xu, J., Ng, S.K. and Chua, T.S., 2025. Media Source Matters More Than Content: Unveiling Political Bias in LLM-Generated Citations. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 17256-17276).

Donkor, P., 2025. Exploring and Mitigating Implicit Bias in Large Language Models: A Cross-Domain Evaluation Framework. In *Proceedings of the AAAI Conference on Artificial Intelligence*.

Guo, Y., Guo, M., Su, J., Yang, Z., Zhu, M., Li, H., Qiu, M. and Liu, S.S., 2024. Bias in Large Language Models: Origin, Evaluation, and Mitigation. *arXiv preprint arXiv:2411.10915*.

Holm, E.M., 2024. Ethical AI in Islamic Studies: What Four AI Models got Right (and Wrong) on Three Questions on Islamic Law. *Leibniz-Zentrum Moderner Orient (ZMO) Blog*, #18.

Lee, M.H.J. and Lai, C.K., 2025. Implicit Bias-Like Patterns in Reasoning Models. *arXiv preprint arXiv:2503.11572*.

Liu, Z., Qian, S., Cao, S. and Shi, T., 2025. Mitigating Age-Related Bias in Large Language Models: Strategies for Responsible Artificial Intelligence Development. *INFORMS Journal on Computing*.

Peters, U. and Chin-Yee, B., 2025. Generalization bias in large language model summarization of scientific research. *Royal Society Open Science*, 12(4), p.241776.

Stanford HAI, 2025. *The 2025 AI Index Report*. Stanford University: Stanford Institute for Human-Centered Artificial Intelligence.